美团外卖广告模型演进之路

谢乾龙

2018.11

外卖广告

品牌广告

CPM

推荐广告

CPC

搜索广告

CPC

营销广告

CPS

外卖广告

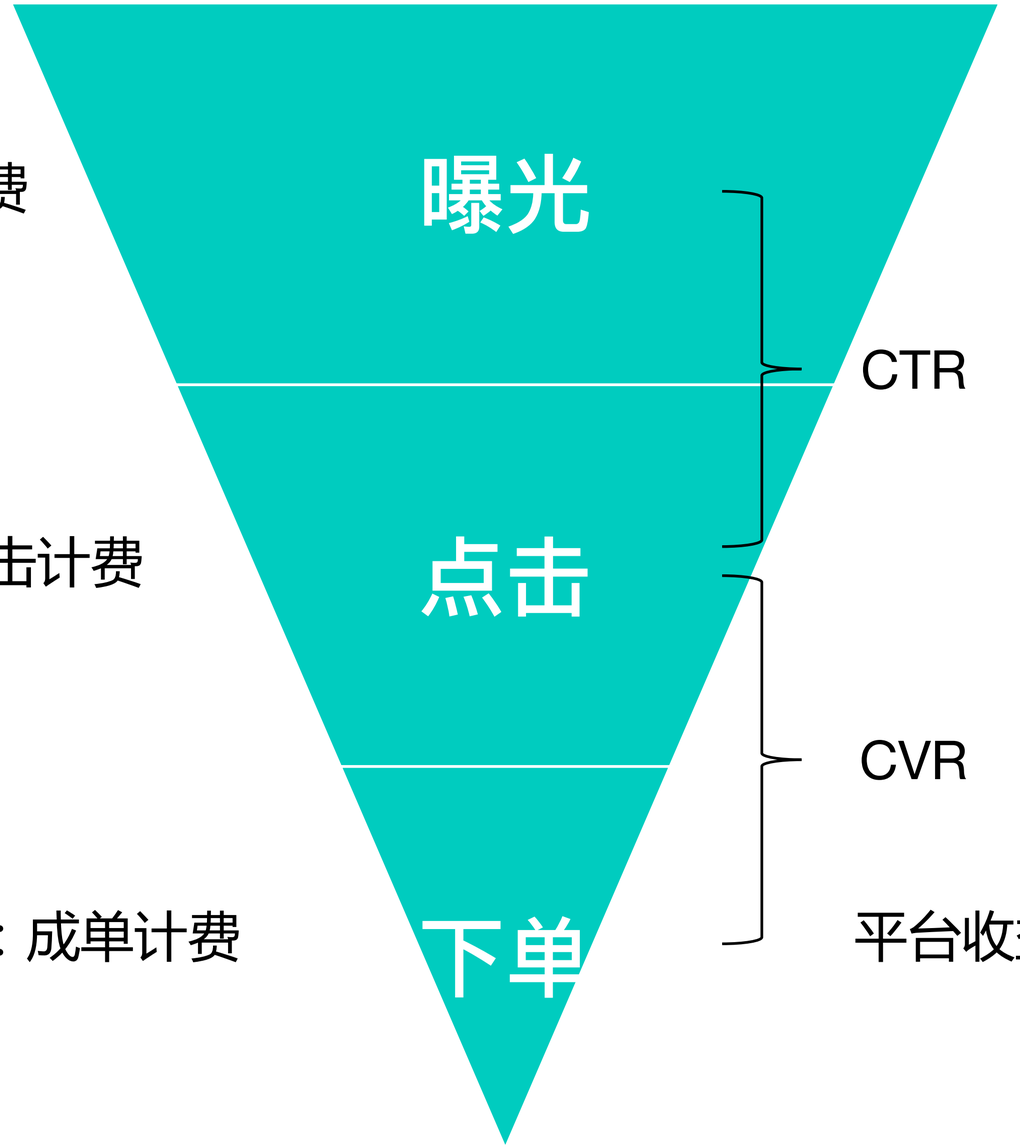

CPM：展示计费

CPC：点击计费

CPS：成单计费

CTR

CVR

平台收益=bid

平台收益=CTR * bid

平台收益=CTR * CVR * bid

风险由商户向平台转移

技术挑战增加

外卖广告

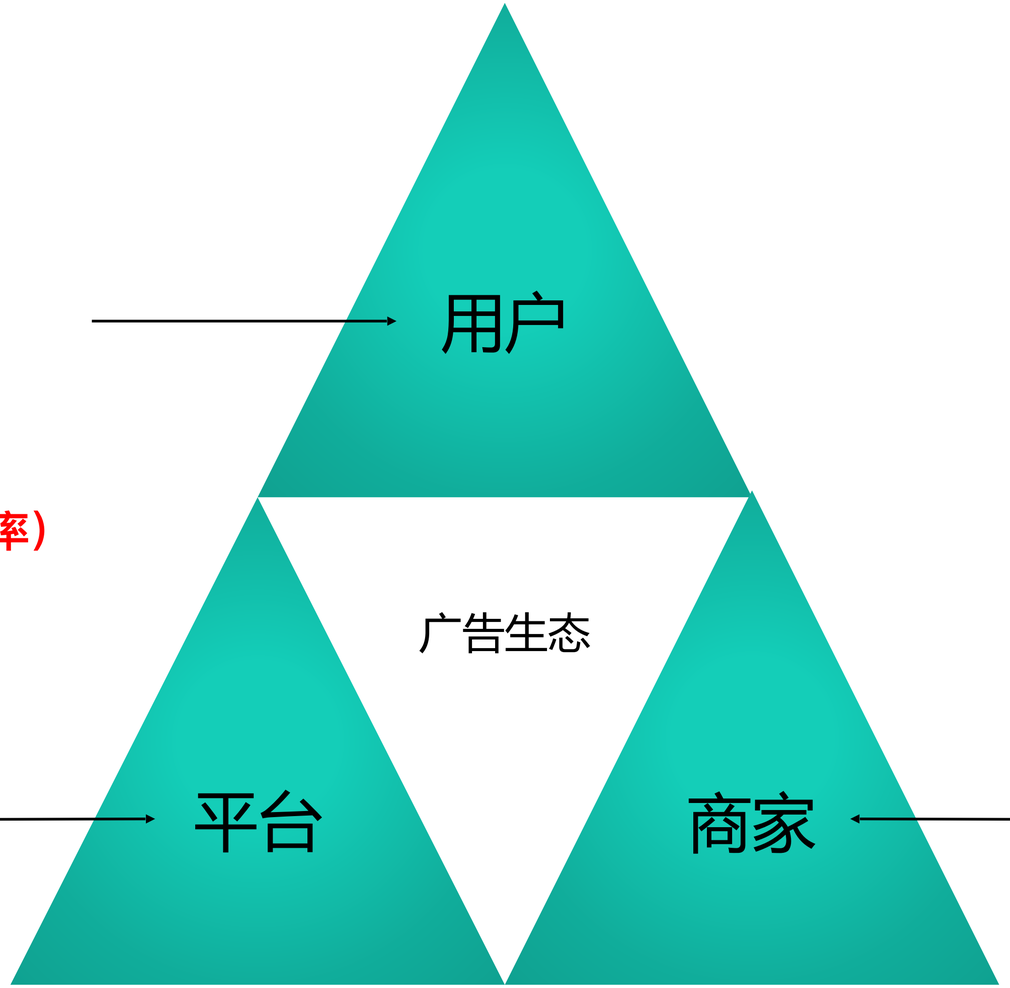

用户体验

短期：ctr，cvr

长期：ror（复购率）

千次展现收益（CPM）

$$CPM = \begin{cases} bid \\ ctr * bid \\ ctr * cvr * bid \end{cases}$$

CPM广告

CPC广告

CPS广告

$$ROI = \frac{GMV}{CPM} = \begin{cases} \frac{ctr * cvr * price}{bid} \\ \frac{cvr * price}{bid} \\ \frac{price}{bid} \end{cases}$$

投入产出比（ROI）

业界模型发展历程

- 优点：简单高效
- 缺点：线性，表达能力弱

线性模型：

LR（LBFGS，OWLQN）

Online-LR（SGD，FTRL）

FM

FFM

- 优点：非线性，可解释性
- 缺点：不能online，高维离散特征

树模型：

GBDT

XGBoost

LightGBM

- 优点：精度高，表达能力强
- 缺点：性能，可解释性

神经网络模型

DNN

Wide&Deep

FNN

DeepFM

DCN

…

外卖广告模型演进

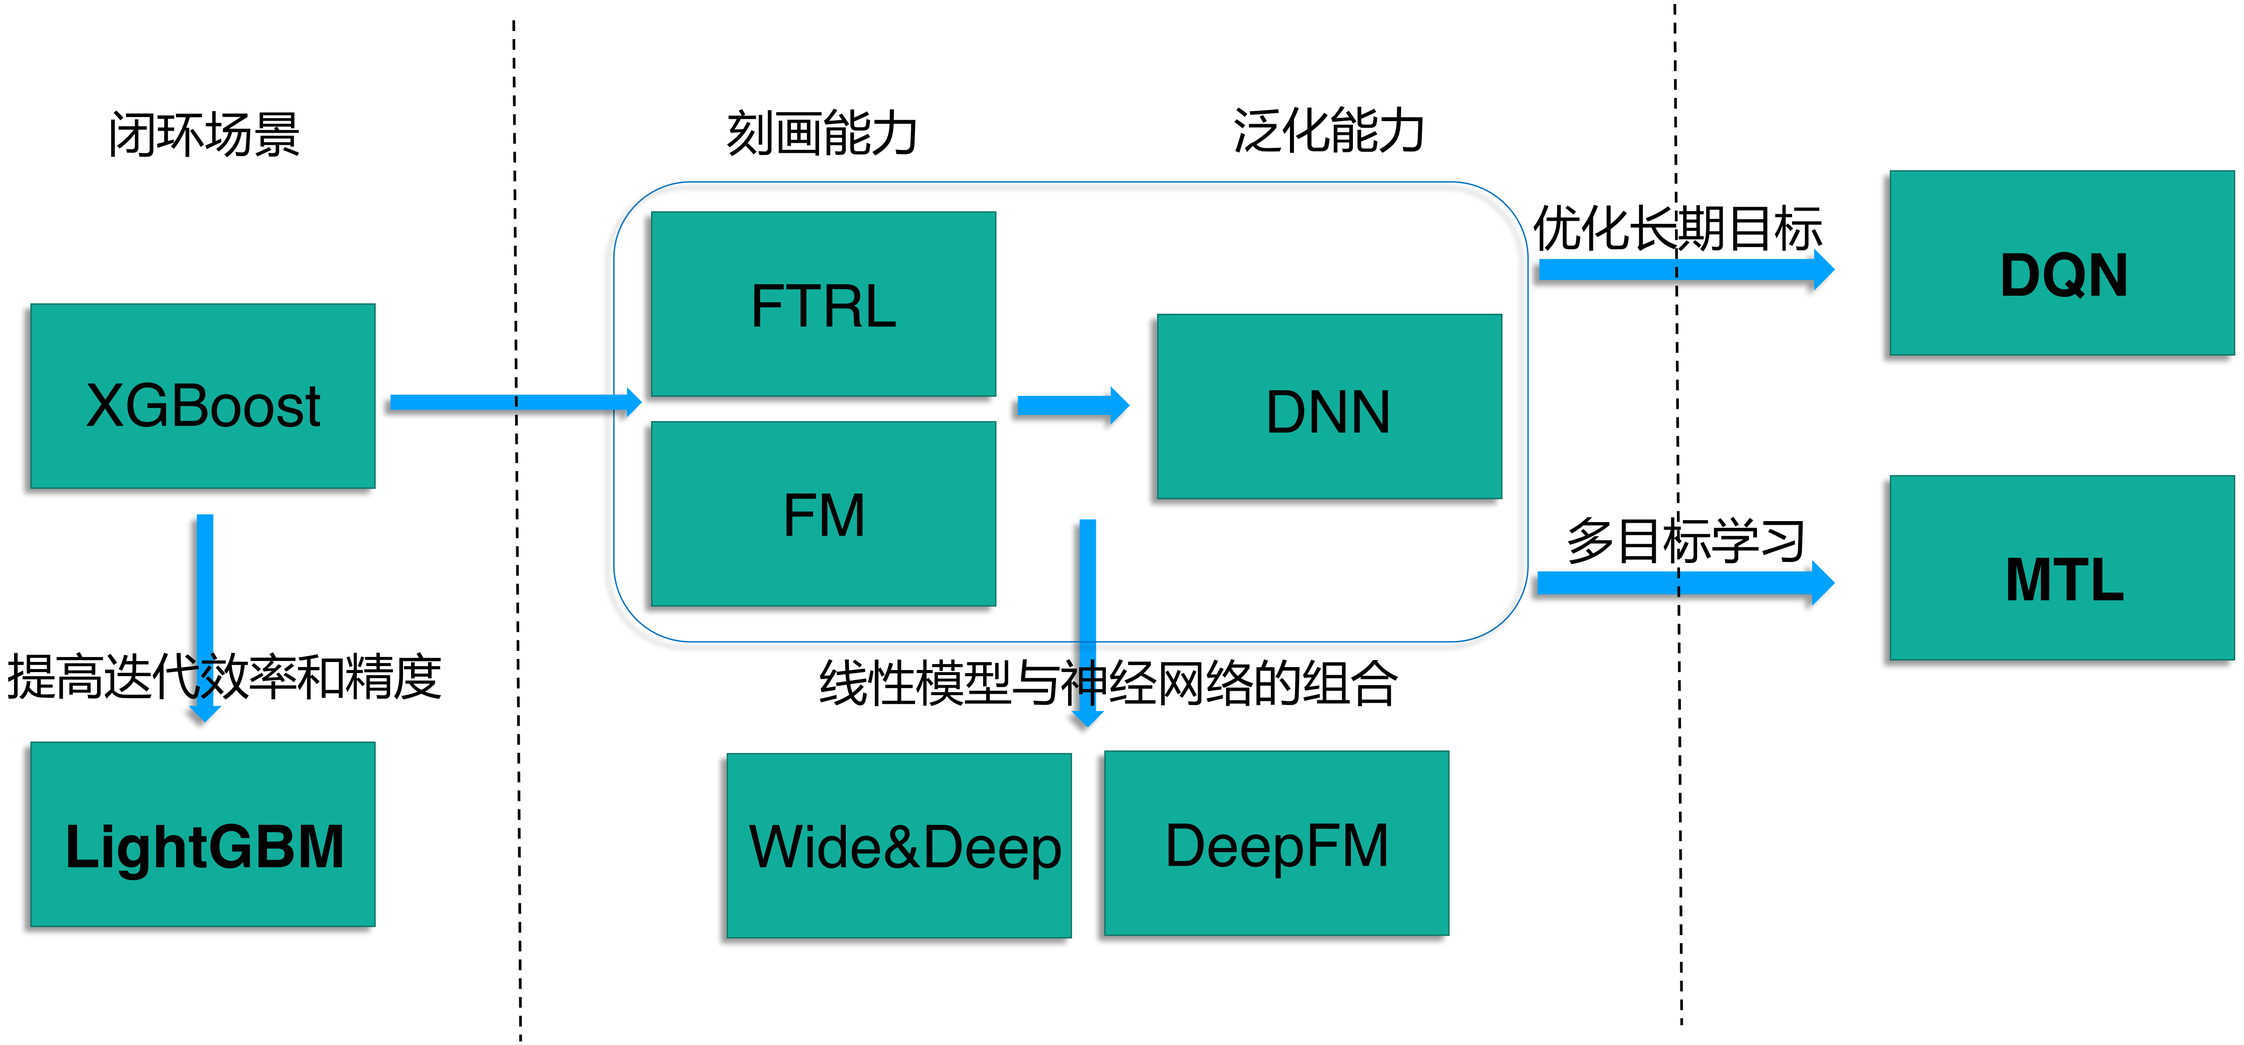
闭环场景
刻画能力
泛化能力
XGBoost
FTRL
FM
DNN
优化长期目标
DQN
多目标学习
MTL
提高迭代效率和精度
LightGBM
线性模型与神经网络的组合
Wide&Deep
DeepFM

目录

目录

树模型

- XGBoost
- LightGBM

神经网络

- DNN
- MTL

强化学习

- DQN

GBDT & XGBoost

01 GBDT: Gradient Boosting Decision Tree

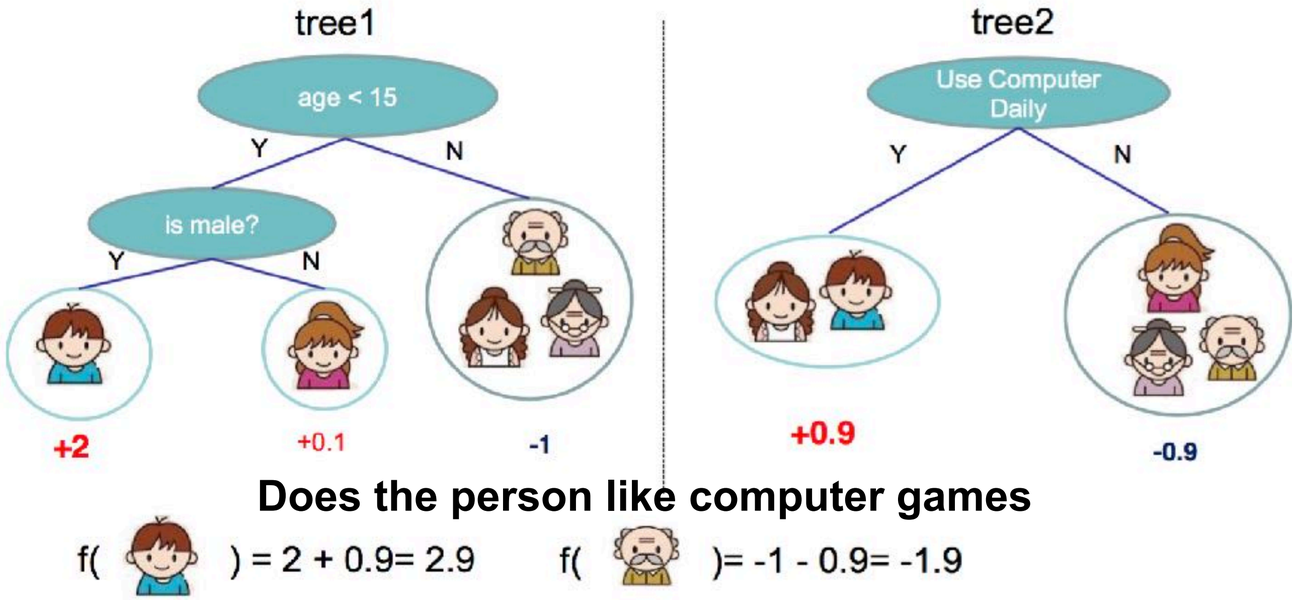

02 XGBoost: eXtreme Gradient Boosting

XGBoost是GBDT的一种实现

XGBoost

- XGBoost的实现方式

1，二阶泰勒展开：损失函数更精准，收敛速度更快

2，引入正则项：防止过拟合

3，缺失值处理：自动学习特征缺失值的分裂方向

4，直方图算法：如右图

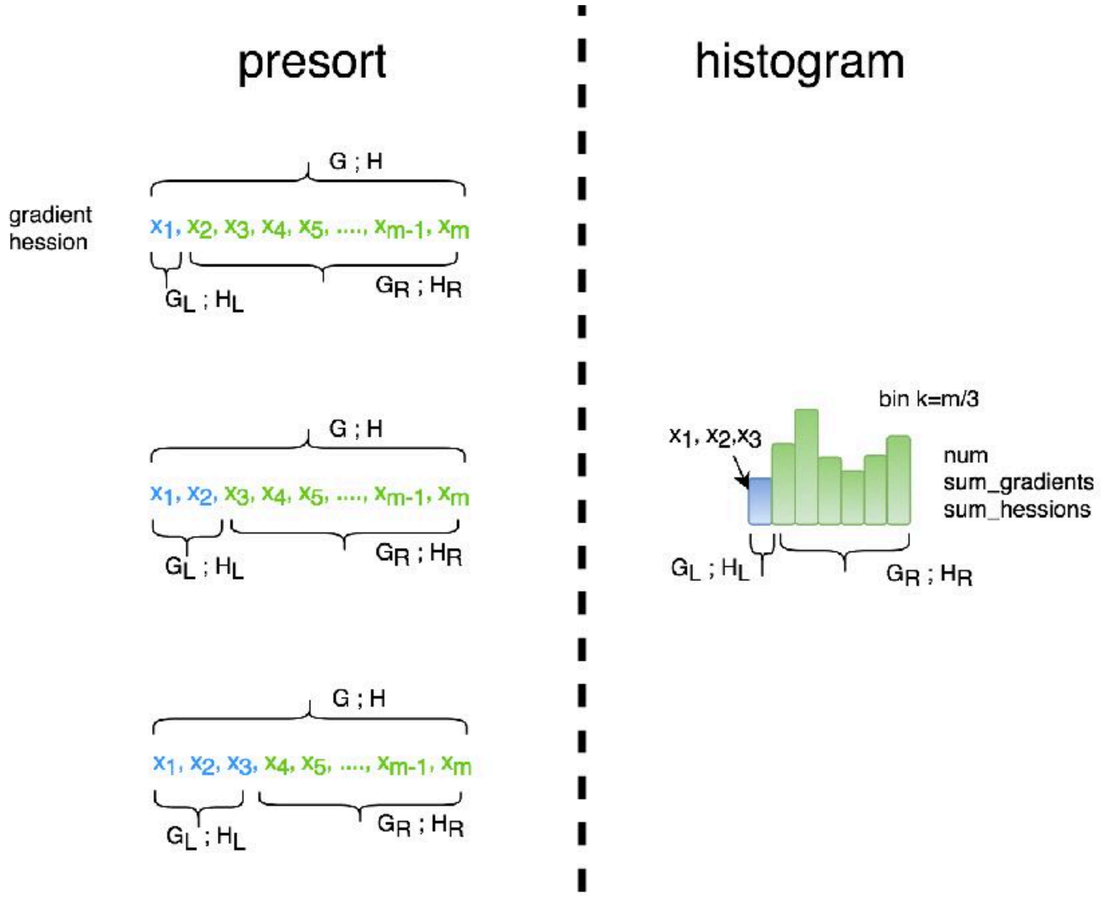

LightGBM

- LightGBM改进

精度提升

- Leaf-wise分裂

性能优化

- 样本采样（GOSS）
- 特征合并（EFB）
- 分布式通信优化

易用性

- 支持类别特征
- 支持忽略特征

LightGBM—性能优化

- GOSS（Gradient-based One-Side Sampling）

  保留梯度大的样本，采样梯度小的样本，并提高其权重

- 优点

  既减少了数据量，又能有效保持精度

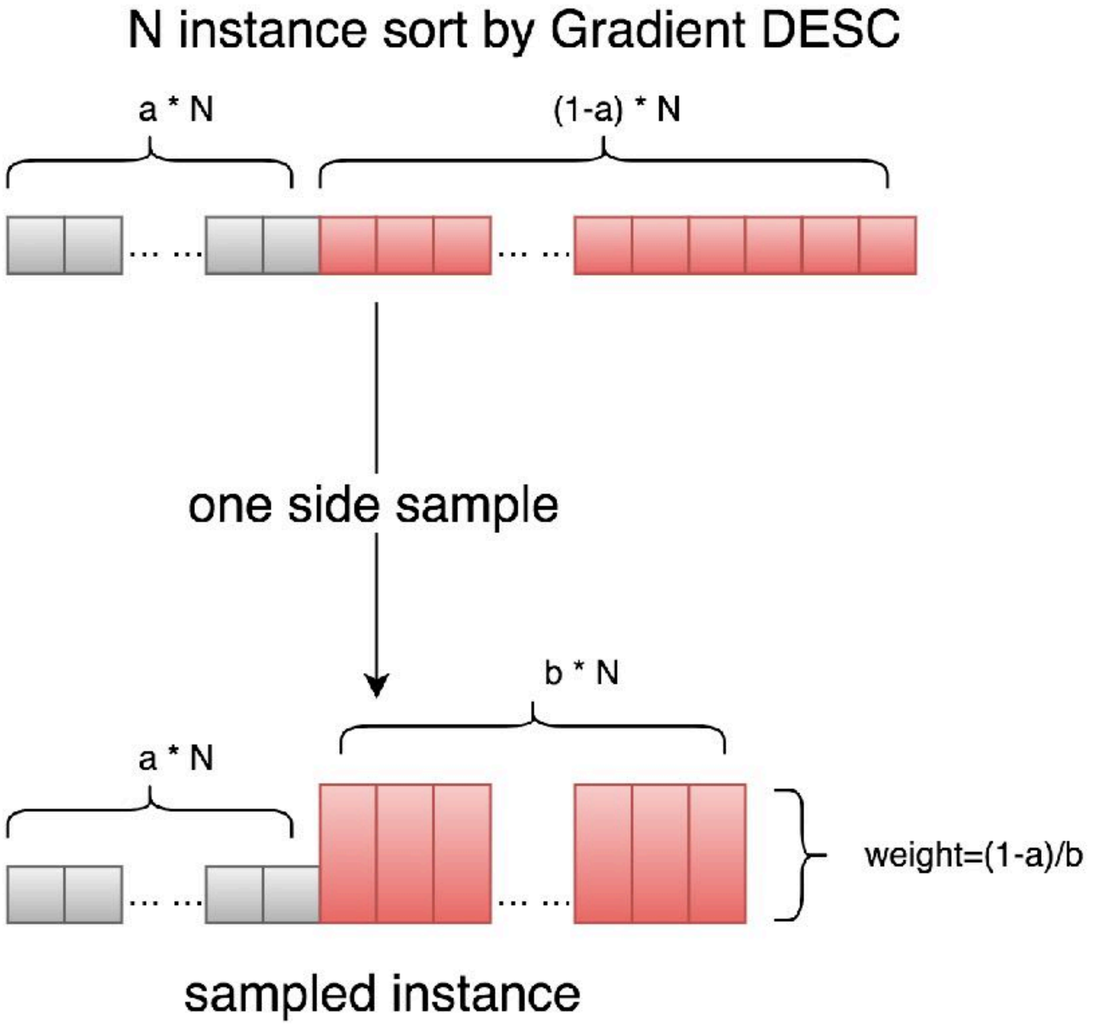

LightGBM—性能优化

- EFB（Exclusive Feature Bundling）

  建立直方图的时间复杂度可以由O(#data * #feature) 减小到 O(#data * #bundle)

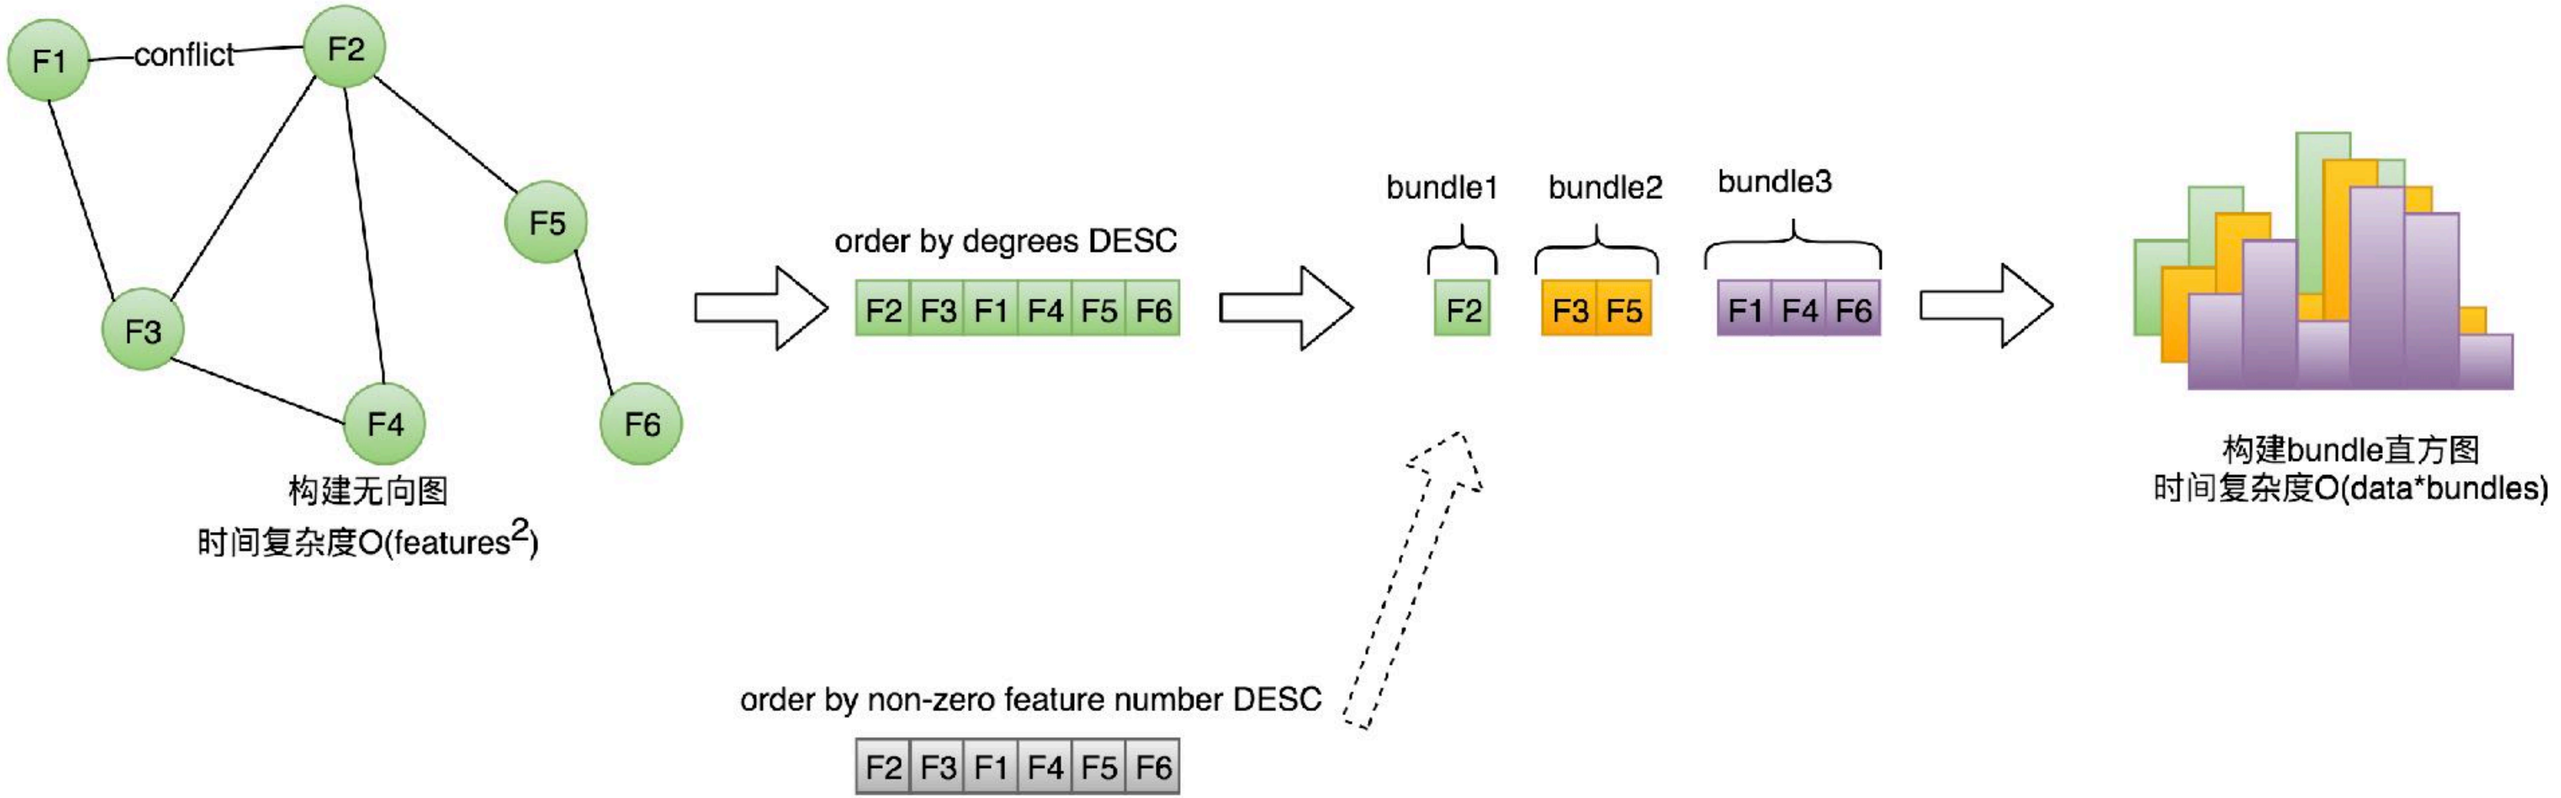

LightGBM—并行化

- LightGBM中的并行

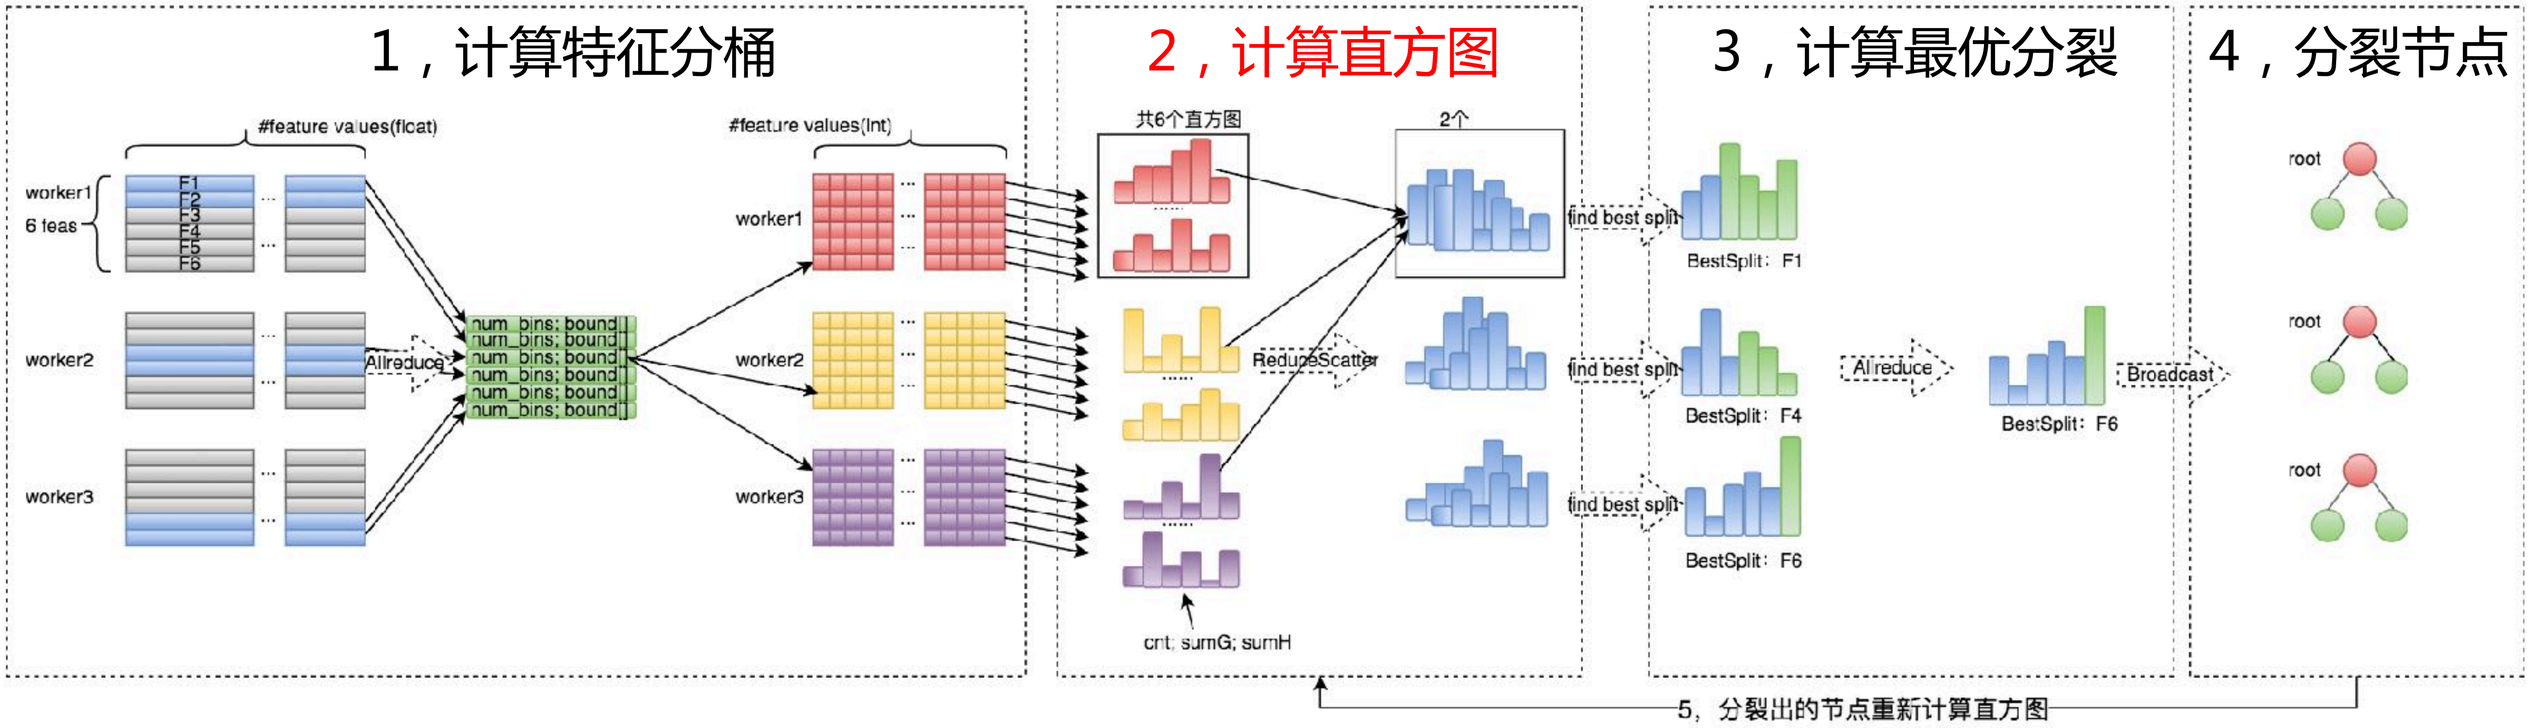

LightGBM—并行化

02 建立特征直方图

1. 建立本地直方图

2.合并全局直方图

- AllReduce：对所有计算节点上的数值进行归约操作
- ReduceScatter：只保留归约后的部分结果

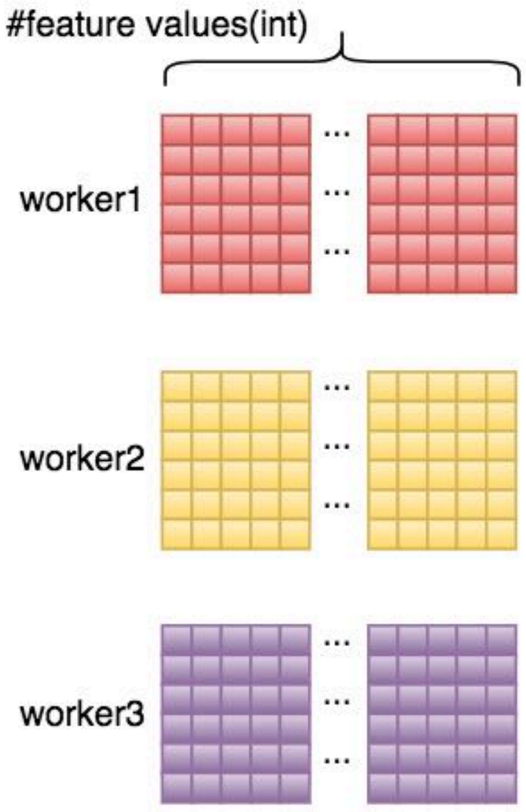

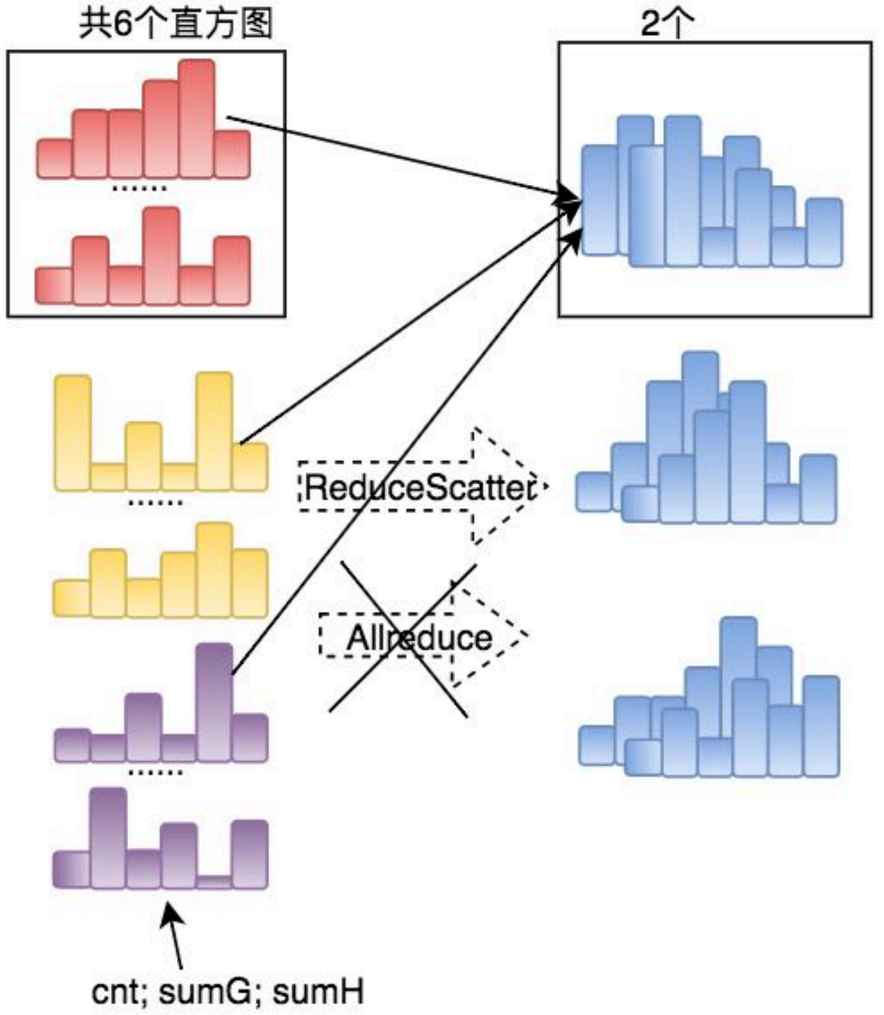

LightGBM—并行化

- ReduceScatter

XGBoost->AllReduce

LightGBM->Recursive Halving

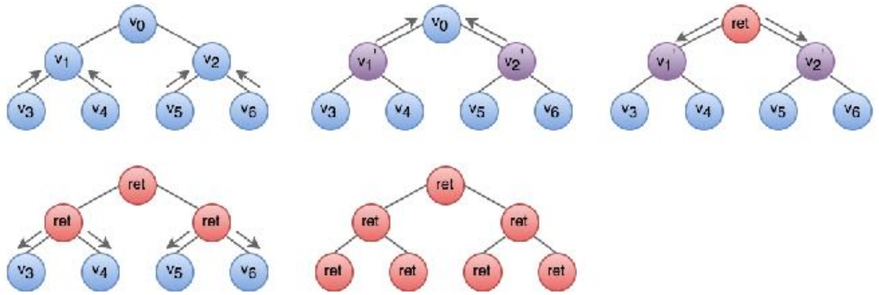

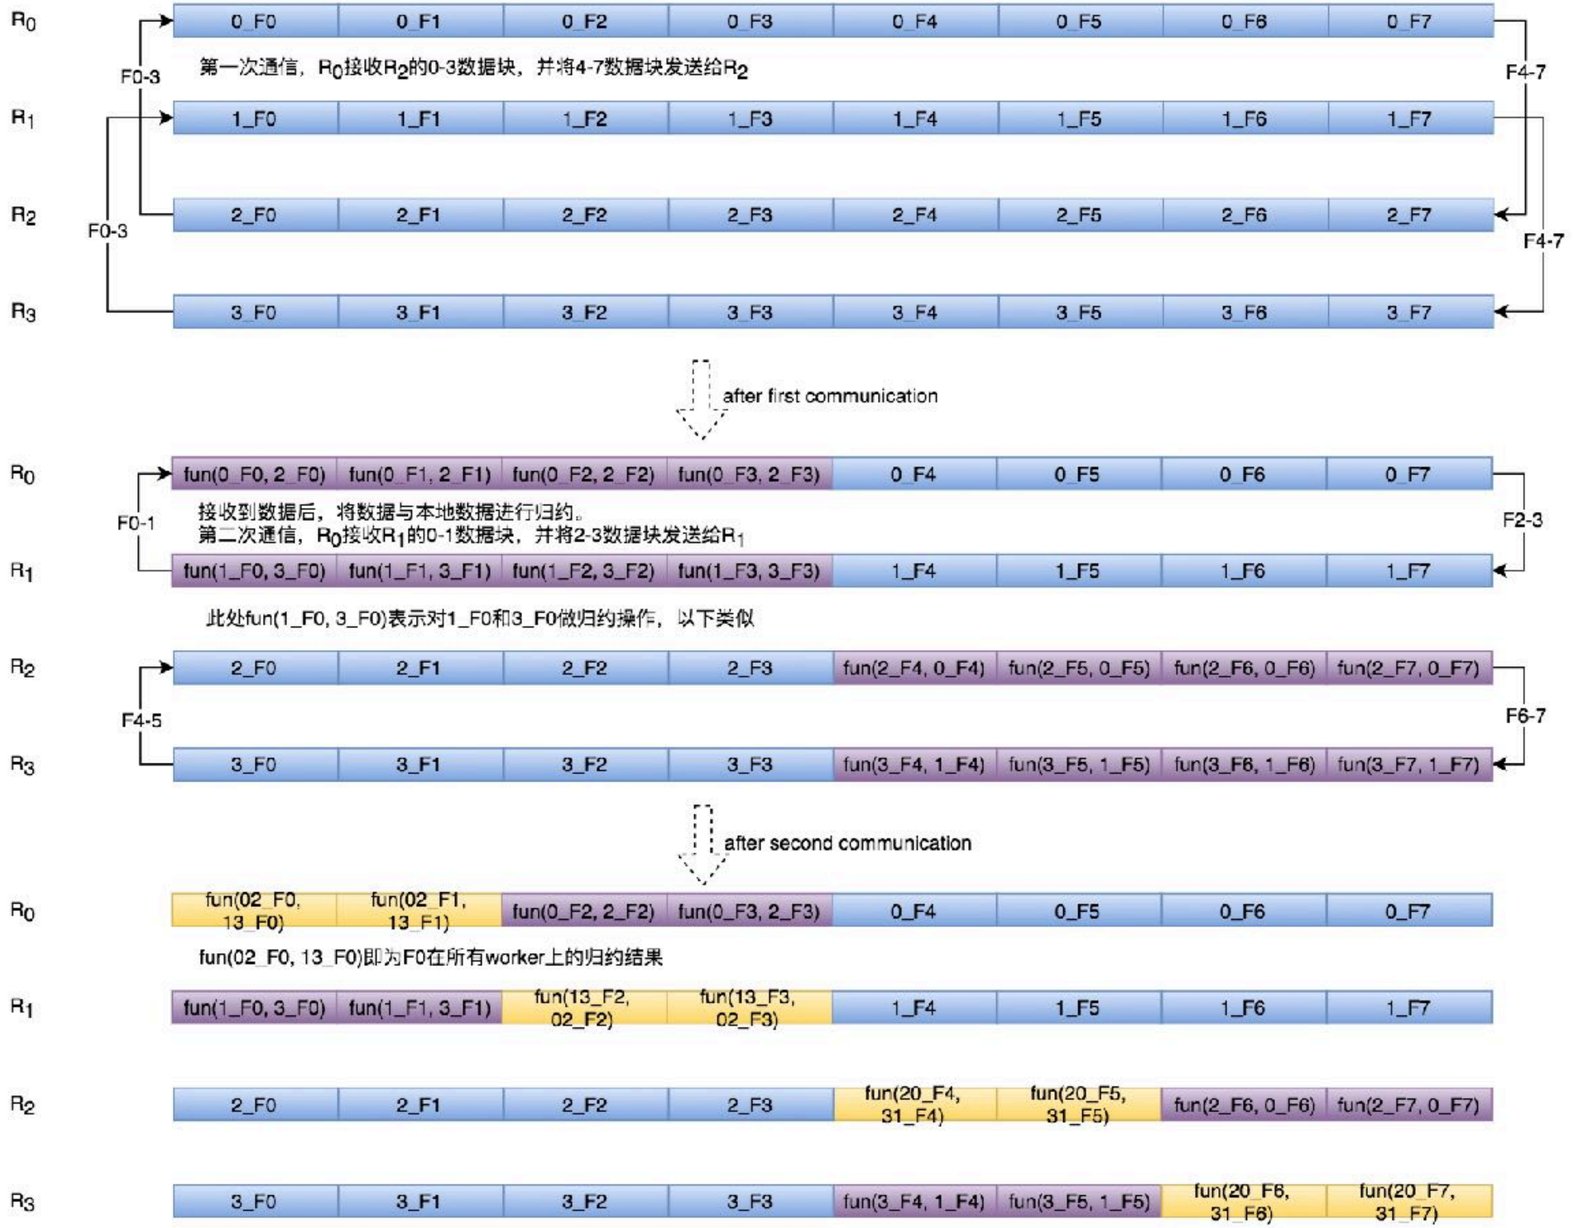

优点：大大减少通信数据量

缺陷：只适用于2^k worker情况

外卖广告实践—Yarn-LightGBM

- 支持yarn环境
- 支持HDFS文件

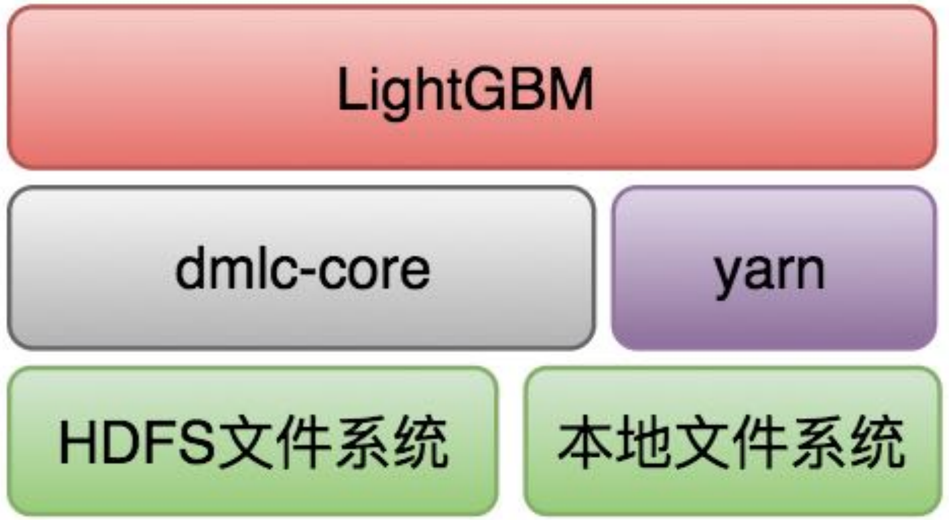

架构图

外卖广告实践—Yarn-LightGBM

- 优化非2^k个worker时的通信时间

执行步骤	XGBoost 64workers	LightGBM 64workers	LightGBM 65workers	Yarn-LightGBM 65workers
建立本地直方图	2.032276s	1.134293s	1.962546s	1.812981s
对所有直方图加和	13.681048s	2.097936s	28.615881s	3.19341s
同步分裂属性	19.017187s	0.907549s	3.051622s	1.851814s
分裂叶子	0.259526s	0.084525s	0.177973s	0.09139s
Trained a tree	35.272322s	4.436463s	34.086826s	6.949595s

优化： Virtual Rank + Recursive Halving

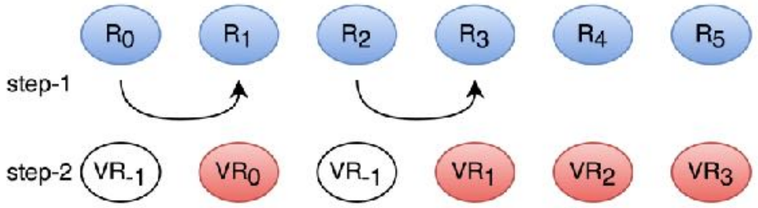

Step 1

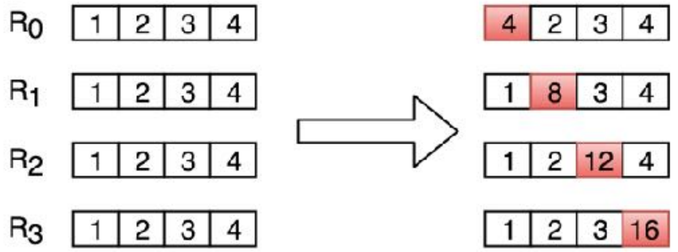

Step 2

外卖广告实践—Yarn-LightGBM

➢总结：

LightGBM	Yarn-LightGBM
1. 只支持MPI/Socket	1. 通过yarn，支持Spark集群
2. 只能读本地数据	2. 通过dmlc-core，支持HDFS文件
3. 性能不稳定	3. 分布式通信算法改进
4. 效果不稳定	4. 训练代码优化
	5. 易用性优化

✓ 以上特性已经被合并到github开源版本中

➢效果：

- 训练速度比XGBoost提升2倍
- 线上效果正向
- 目前在集团内部多个团队应用，性能提升1-3倍

目录

树模型

- XGBoost
- LightGBM

神经网络

- DNN
- MTL

强化学习

- DQN

神经网络

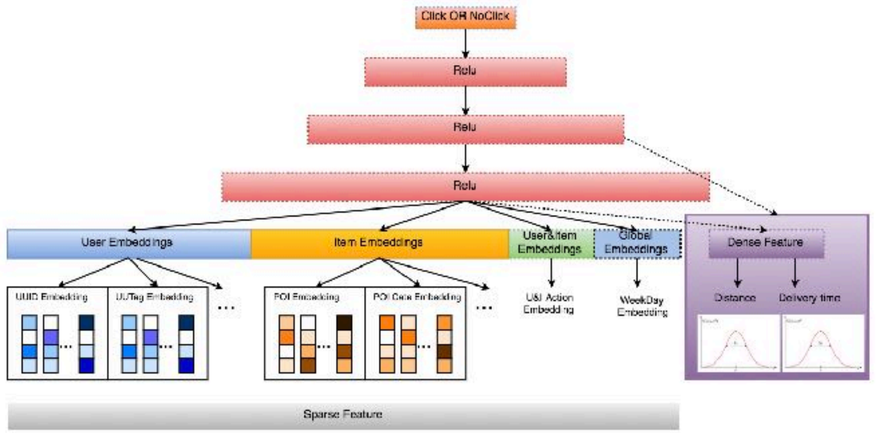
Click OR NoClick
Relu
Relu
Relu
User Embeddings
Item Embeddings
User&Item Embeddings
Global Embeddings
Dense Feature
UUID Embedding
UUTag Embedding
POI Embedding
POI Cate Embedding
U&I Action Embedding
WeekDay Embedding
Distance
Delivery time
Sparse Feature

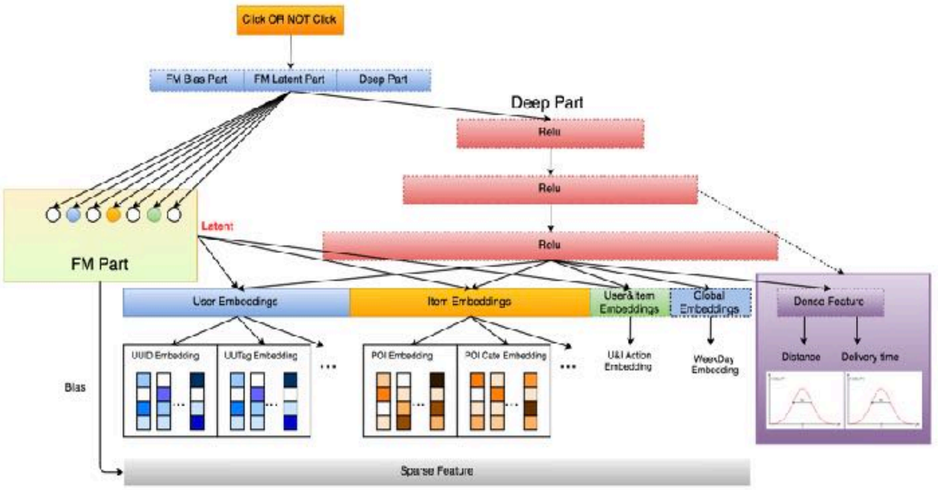
Click OR NOT Click
FM Bias Part
FM Latent Part
Deep Part
Deep Part
Relu
Relu
Relu
Latent
FM Part
User Embeddings
Item Embeddings
User&Item Embeddings
Global Embeddings
Dense Feature
UUID Embedding
UUTag Embedding
POI Embedding
POI Cate Embedding
U&I Action Embedding
WeekDay Embedding
Distance
Delivery time
Bias
Sparse Feature

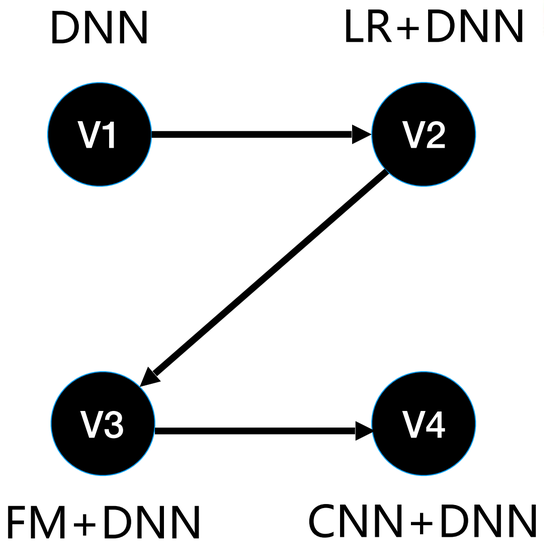
DNN
LR+DNN
V1
V2
V3
V4
FM+DNN
CNN+DNN

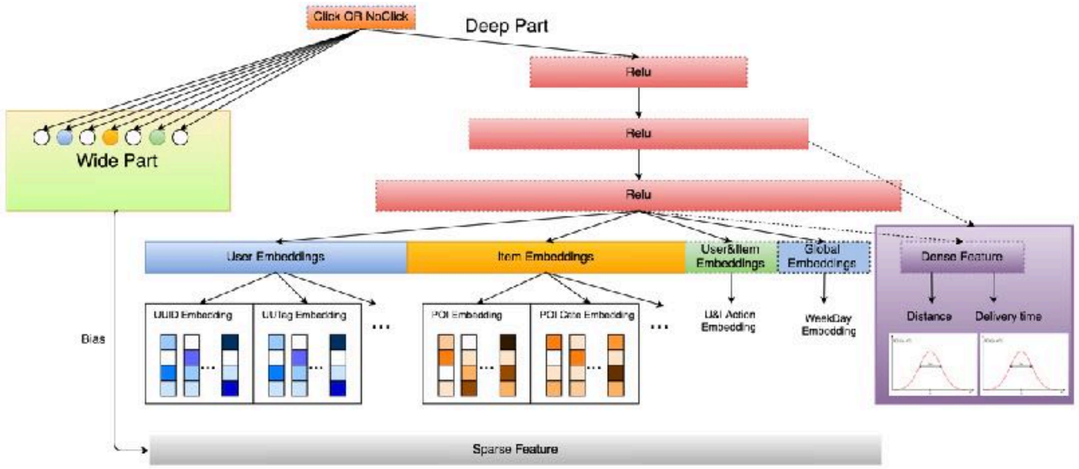
Click OR NoClick
Deep Part
Wide Part
Relu
Relu
Relu
User Embeddings
Item Embeddings
User&Item Embeddings
Global Embeddings
Dense Feature
UUID Embedding
UUTag Embedding
POI Embedding
POI Cate Embedding
U&I Action Embedding
WeekDay Embedding
Distance
Delivery time
Bias
Sparse Feature

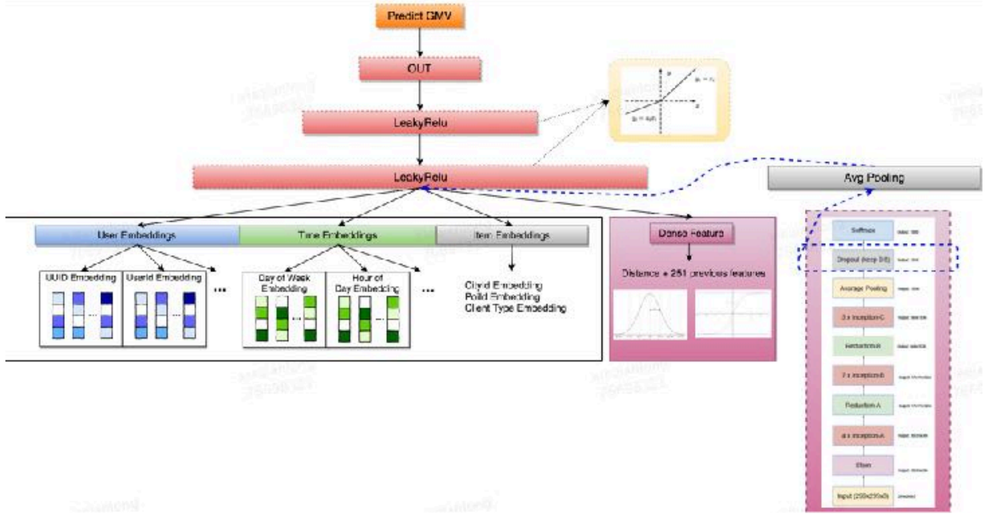
Predict GMV
OUT
LeakyRelu
LeakyRelu
Avg Pooling
User Embeddings
Time Embeddings
Item Embeddings
Dense Feature
UUID Embedding
Userid Embedding
Day of Week Embedding
Hour of Day Embedding
Distance + 251 previous features
Client Embedding
Poiid Embedding
Client Type Embedding

MTL-背景

整体预估：不够灵活

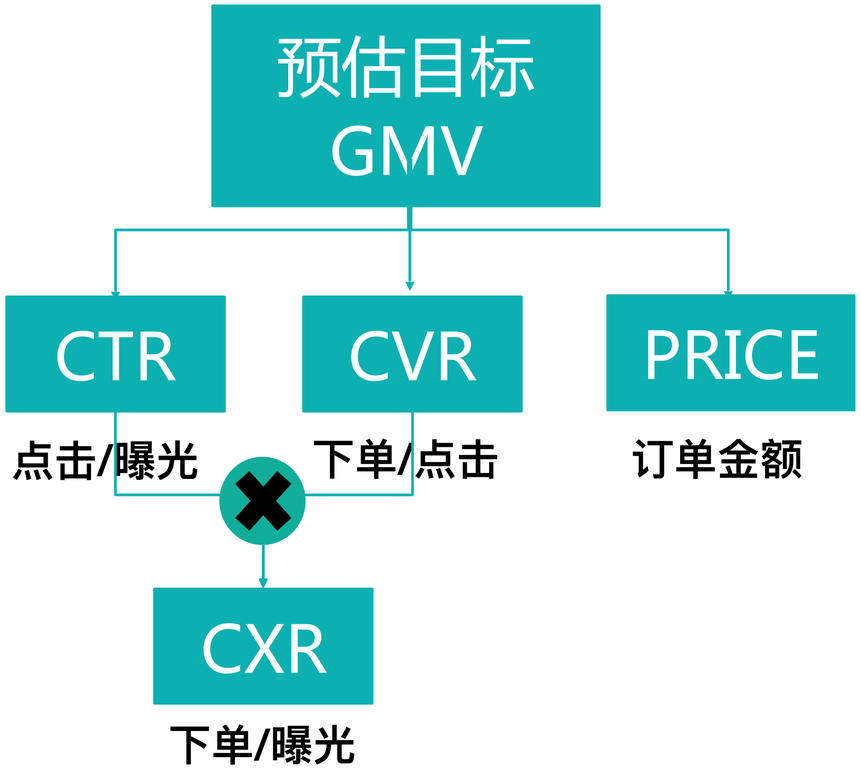

拆分预估：误差大，样本稀疏

问题特点

- ✓ 输入几乎相同
- ✓ 任务高度相关

解决方案

Multi-Task Learning

- ✓ 同时学习和预测多个目标（DNN多输出）
- ✓ 解决CVR，PRICE样本稀疏问题

MTL-技术选型

业内解决方案

经典MTL方案

- ✓ CTR、CVR loss线性加权
- ✓ Joint/Alternate training
- ✓ 共享隐层

阿里ESMM

- ✓ CTR，CXR loss加权
- ✓ CVR作为中间结果
- ✓ 共享Embedding特征表达

外卖广告解决方案

同时学习CTR和CVR

共性

- ✓ loss线性加权
- ✓ Joint training
- ✓ 共享隐层

PRICE怎么办？

特性

- ✓ 样本更加稀疏
- ✓ label的scale

迭代路径

1 初步探索

方法
- MTL同时学习CTR、CXR

效果
- ctr和cxr相对dnn正向

2 上线落地

方法
- MTL同时学习CTR、CVR

效果
- 离线AUC有所提升
- 线上表现正向

问题
- Price如何解决

3 终极方案

方法
- MTL同时学习CTR、CVR、PRICE

效果
- CTR，CVR AUC持平
- MAE正向

MTL-阶段一

✓样本
  ✓曝光

✓Label
  ✓点击、成单

效果（对比DNN）

✓ CTR和CXR均比单目标DNN有所提升

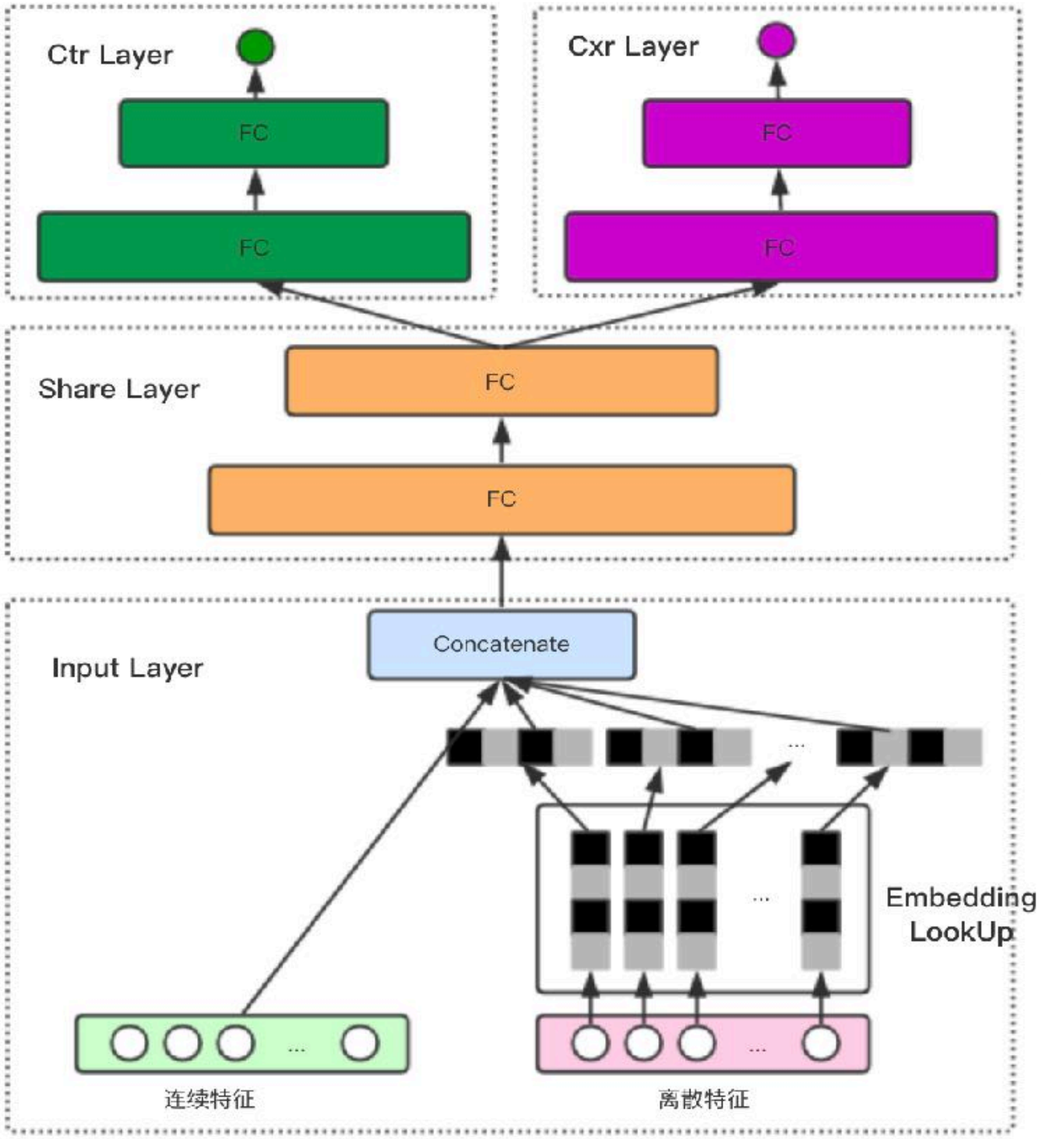

单个Batch的样本分布片段

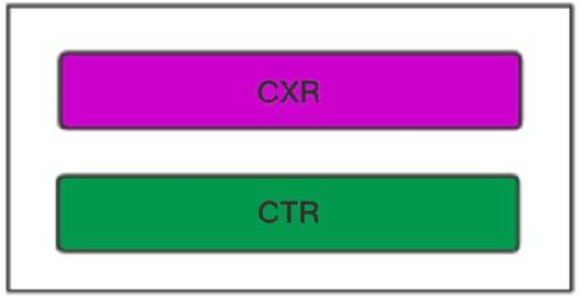

MTL-阶段二

改进 加入CVR Layer

挑战 样本不均 物理含义

应对 Loss加权 Loss约束

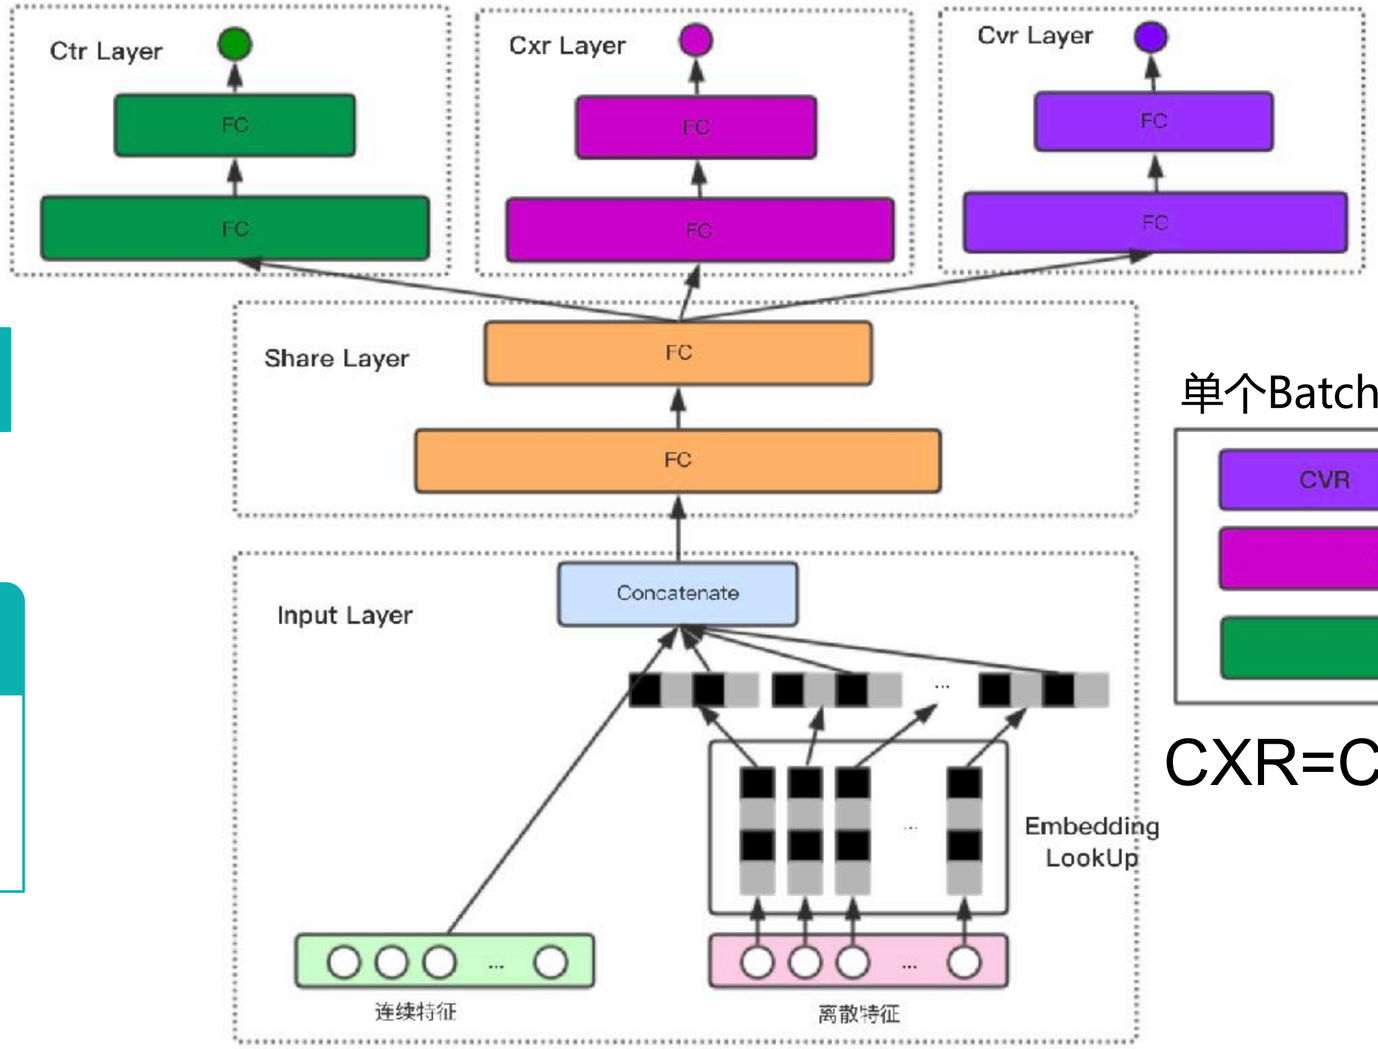

单个Batch的样本分布片段

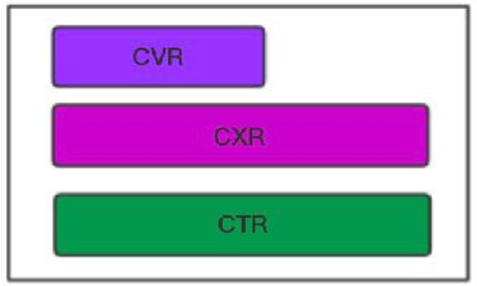

CXR=CTR*CVR

效果（对比DNN）

- ✓ CTR和CVR均比单目标DNN有所提升
- ✓ 线上业务指标正向

MTL-阶段三

改进 加入Price Layer

挑战 样本不均 Loss冲突

应对 Loss加权

- 无法同时收敛

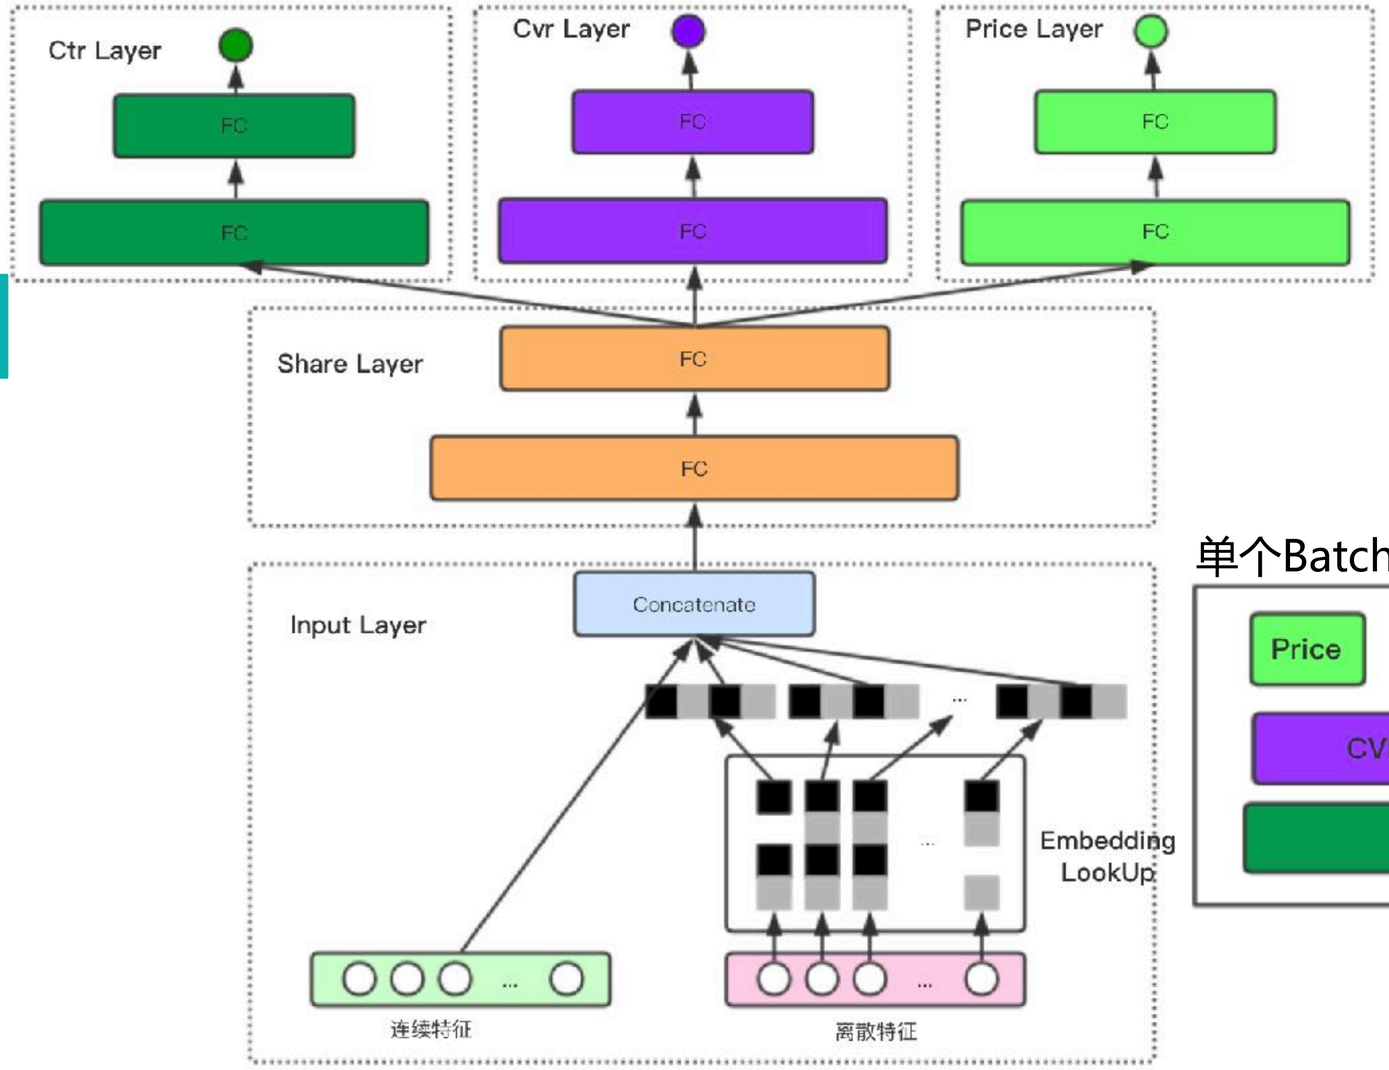

单个Batch的样本分布片段

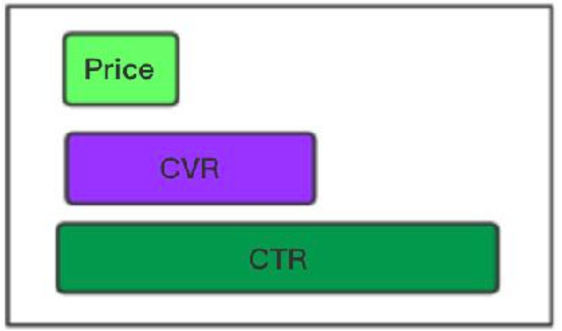

MTL-阶段三

挑战 样本不均 Loss冲突

应对 网络拆分 共享Embedding

效果

- ✓ 同时收敛
- ✓ CTR，CVR AUC持平
- ✓ PRICE MAE正向

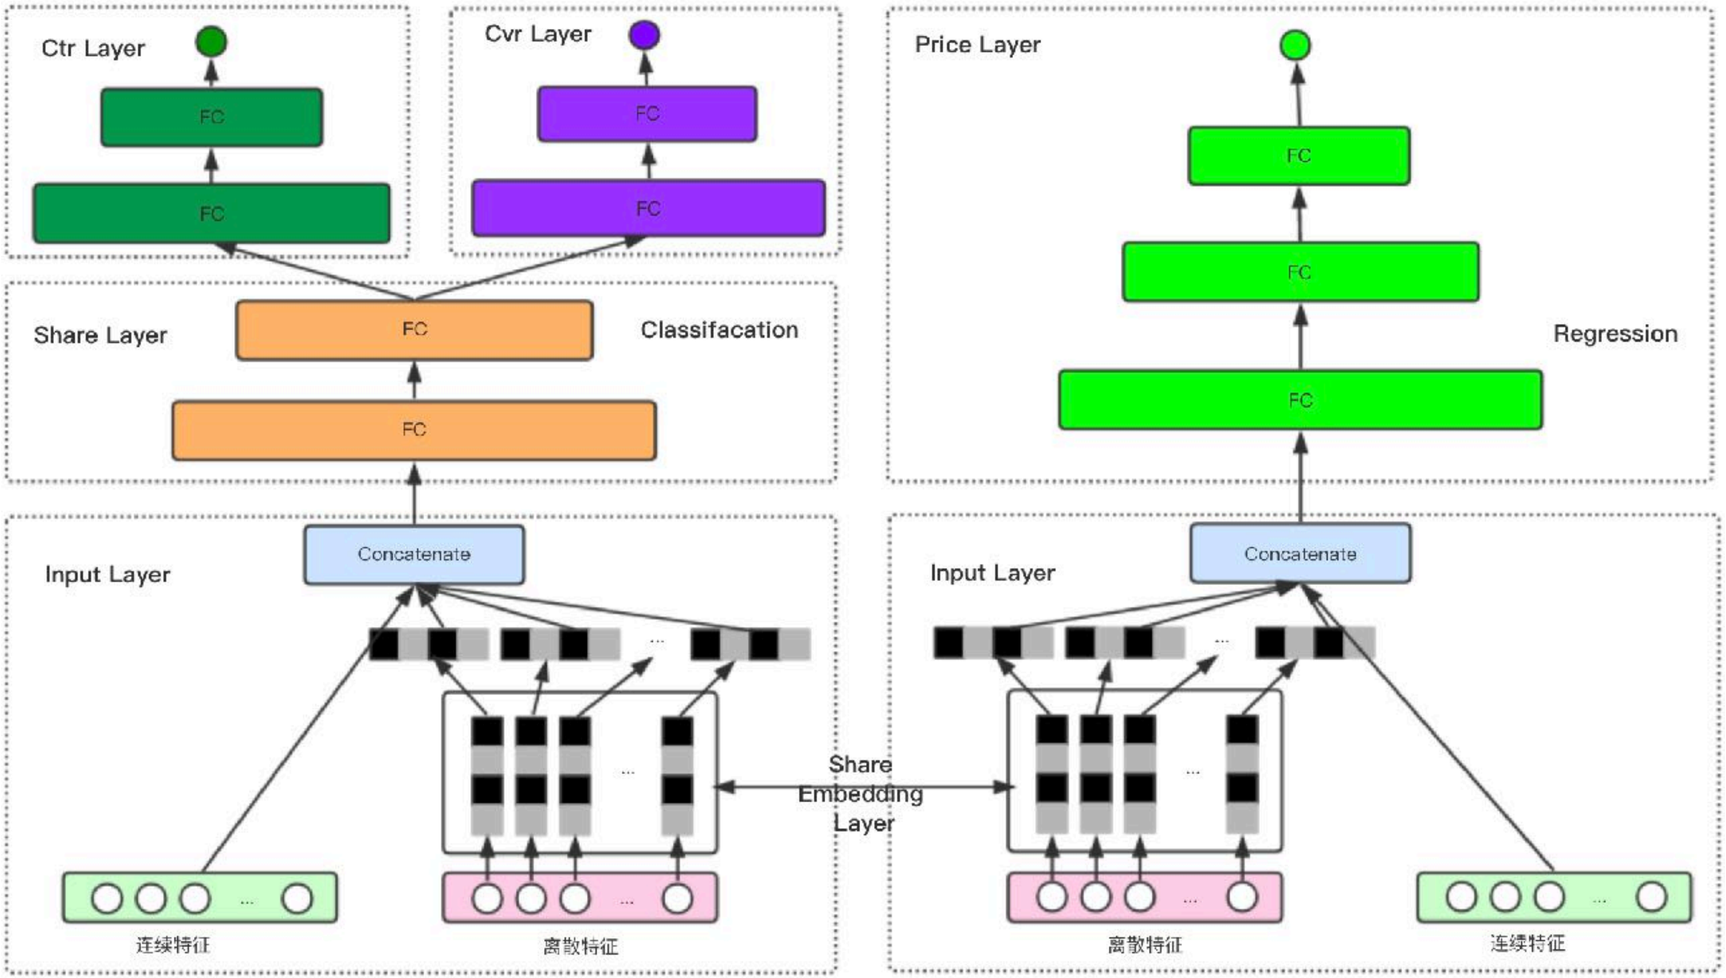

目录

用户体验（UEQ）

✓ 为何要关注用户体验？

- 影响对资源位入口的认知
- 影响用户留存，平台的长期发展

✓ 用户体验如何定义？

- 平台复购率
- 用户活跃度
- 推荐多样性

- 短期用户体验：ctr，cvr
- 长期用户体验：？

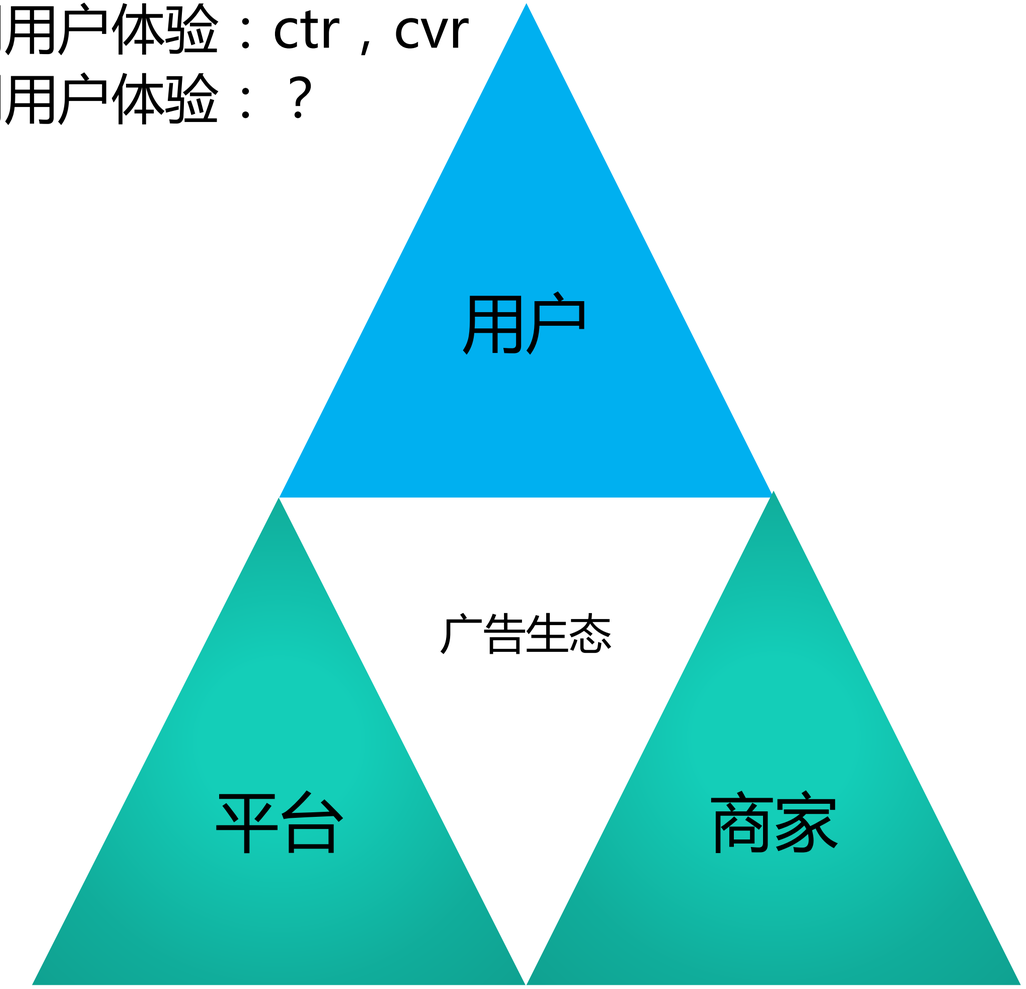

- CPM
- ROI

业务场景

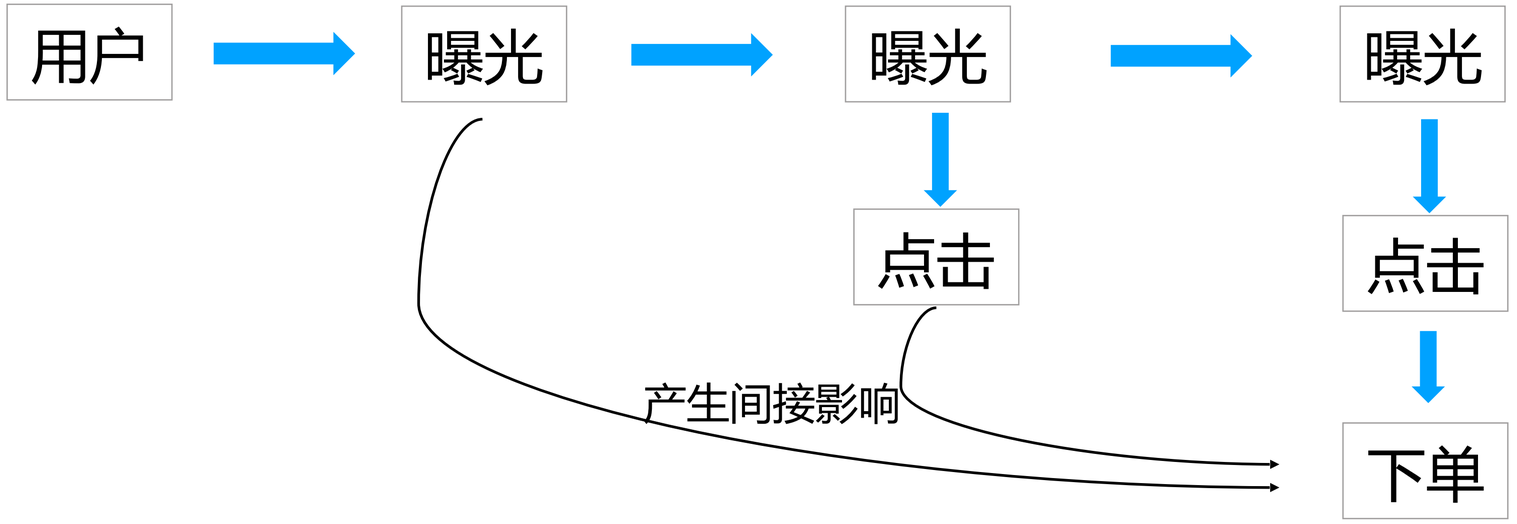

✓ 为什么用强化学习？

- 长期指标，全局最优
- 多目标（复购+活跃度）
- 探索产生多样性

系统框架

强化学习的5大要素：

- environment：用户集和广告集
- state：用户的特征表达
- agent：推荐系统
- action：推荐的广告商家
- reward：复购率+活跃度

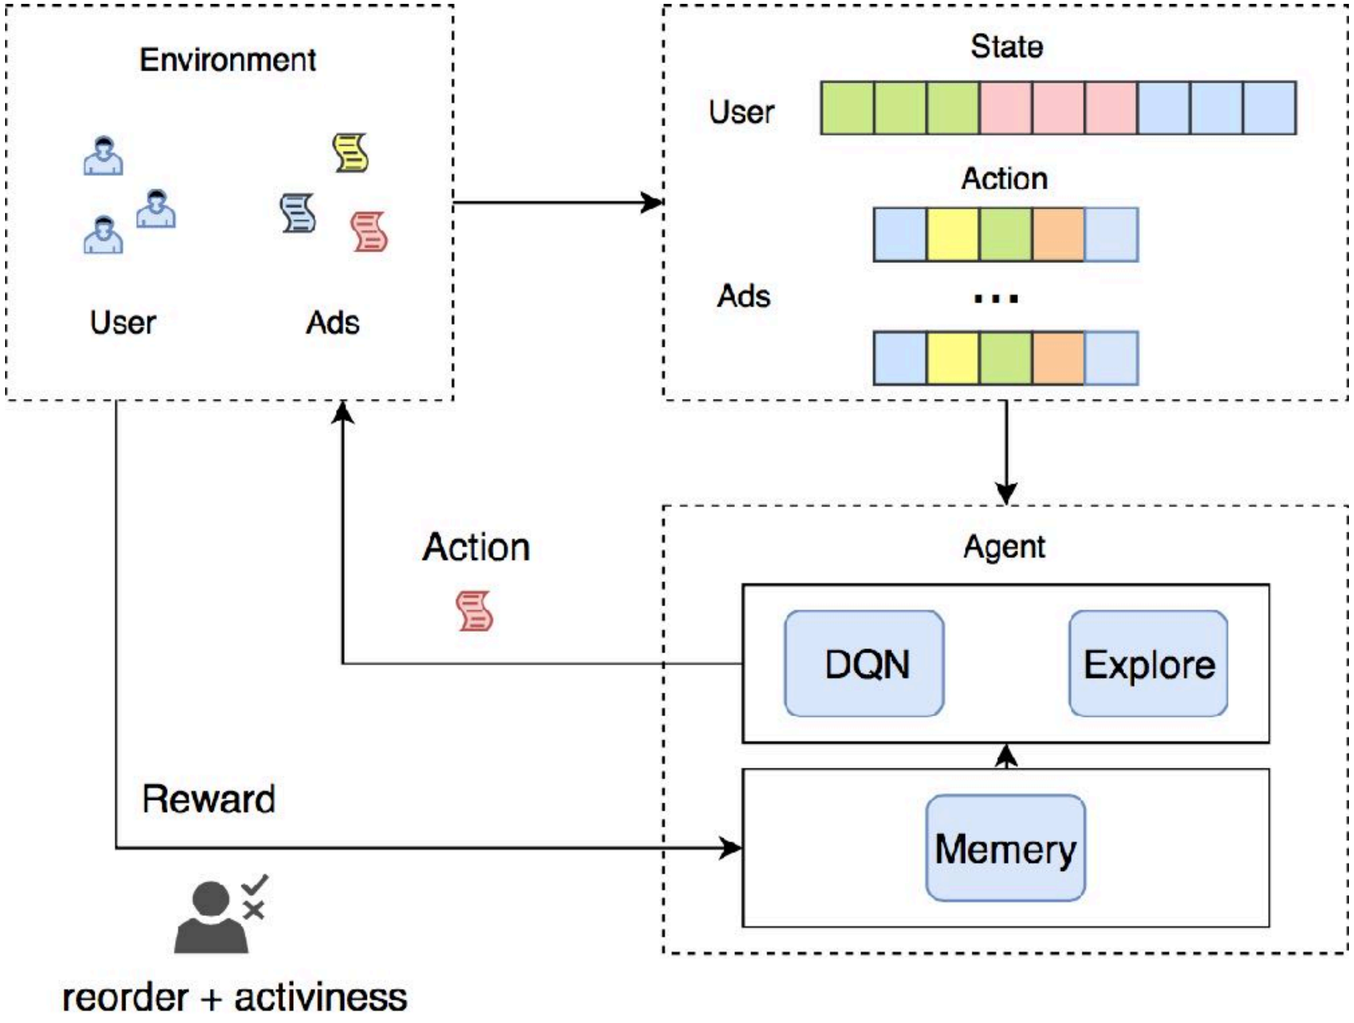

要点详解

- state：用户的特征表达
  - 用户历史浏览/点击序列
  - 用户画像特征：性别，年龄，历史单均价等
  - 地理位置，时间
- action：推荐的广告商家
  - 广告历史统计特征
  - 广告ID类特征
- reward：复购率+活跃度

$$r = \begin{cases} 1 & \text{在平台下单} \\ 0 & \text{未下单} \end{cases}$$

$$r = r * \frac{1}{T}$$ 其中T为距上一次下单的天数，间隔越小reward越大

- agent：DQN->Double DQN->Dueling DQN

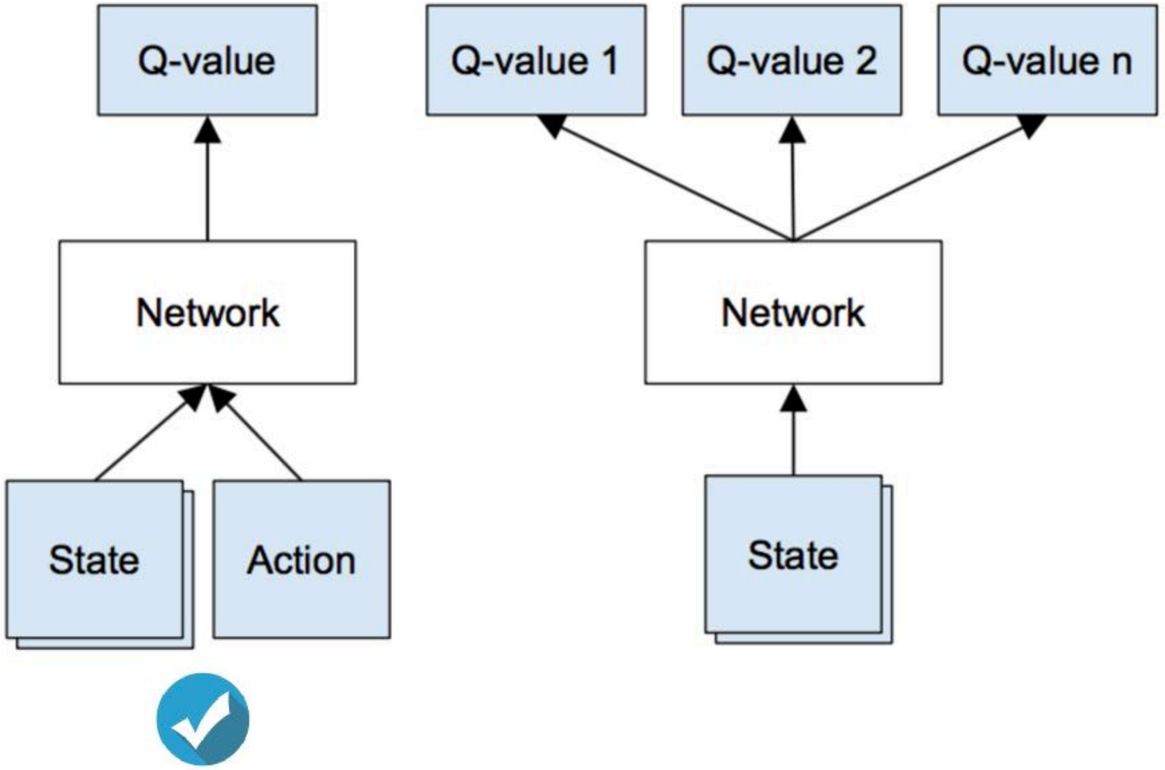

Explore（多样性）

➢e-greedy

一定概率随机推荐，获取充分丰富的样本。

代价大，效果有损

➢UCB(Upper Confidence Bound)

在目前输出Q value的基础上，乘以一个系数： $Q * (1 + \sqrt{\frac{1}{n+1}})$

其中n为广告历史展现的次数，倾向于曝光少的广告

效果优于e-greedy，但仍然不够准确

Explore（多样性）

➢DBGD(Dueling Bandit Gradient Descent)

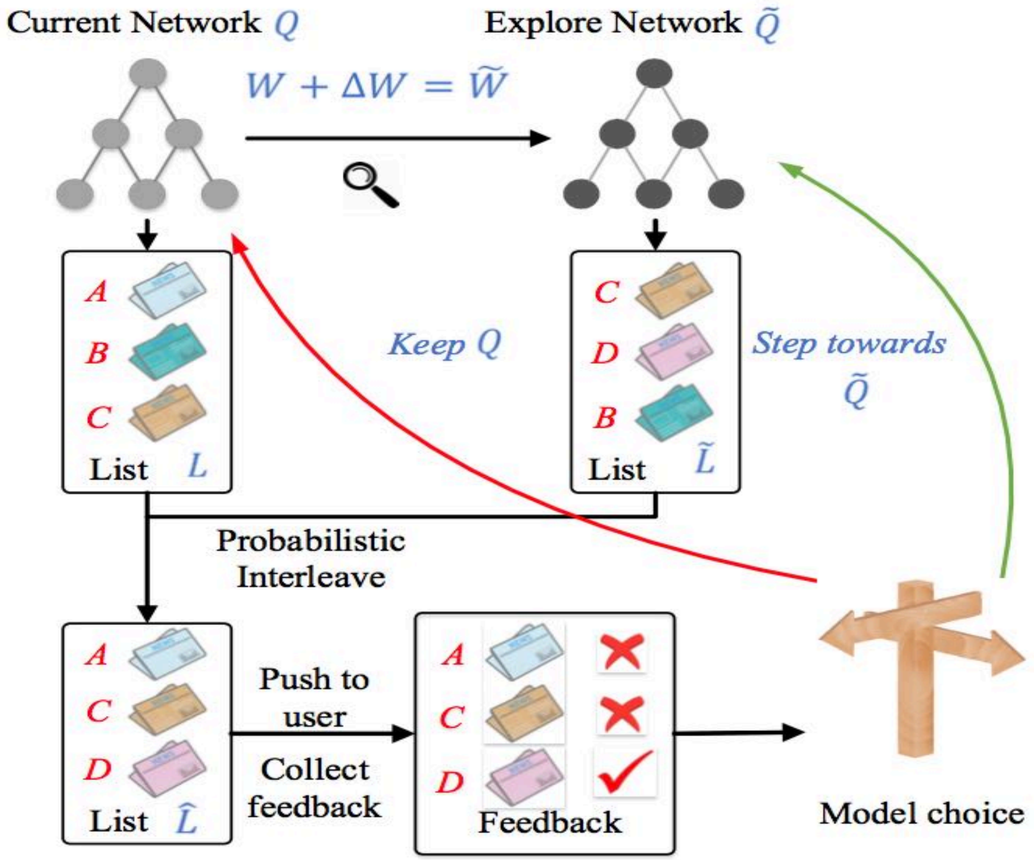

1，对模型参数随机扰动，倾向选择当前策略推荐的item附近的候选集，效果损失最小

2，可以对模型进行实时更新

Q&A